

Diversidad en los Algoritmos Evolutivos

Carlos Segura · Joel Chacón Castillo

Received: date / Accepted: date

Resumen Keywords Diversidad · Multi-objetivo · Convergencia Prematura · Evolución Diferencial

1. Introducción

Los Algoritmos Evolutivos (Evolutionary Algorithms EA) son considerados como uno de los enfoques con mayor eficacia para resolver distintas categorías de optimización. Particularmente, se han aplicado en problemas tanto de dominio continuo [1] como de dominio discreto. Especialmente, los EAs son aplicados para resolver problemas complejos cuyo enfoque determinístico es complicado o imposible [2]. Además, diversas variantes se han utilizado y aplicado en muchos campos, como es en ciencia, economía e ingeniería. Actualmente, los EAs son plenamente conocidos como metaheurísticas [1]. A pesar del éxito que tienen los EAs, existe una dificultad en su adaptación o configuración ante nuevos problemas. Una dificultad popular en el diseño de un EA es obtener un balanceo propio entre exploración y explotación [3]. Sin embargo, no siempre son comprendidas las implicaciones al mantener un grado de diversidad en este balanceo y como son promovidas las exploración y explotación [4]. Desde su inicio los EAs han presentado problemas de convergencia siendo como una desventaja importante [4]. La convergencia prematura es originada cuando todos los miembros de la población están ubicados en una parte reducida del espacio de búsqueda, esta región es distinta a la región óptima y además los componentes seleccionados no son suficientes para escapar de esta región. Basado en esto se han desarrollado varias estrategias para aliviar este problems.

Carlos Segura
Centro de Investigación en Matemáticas, Guanajuato, Mexico
E-mail: carlos.segura@cimat.mx

Joel Chacón Castillo
Centro de Investigación en Matemáticas, Guanajuato, Mexico
E-mail: joel.chacon@cimat.mx

Además en través de varios estudios se ha revelado que mantener una población diversa en un requisito previo para evitar la convergencia prematura [4]. Sin embargo, si la población es muy diversa, entonces un grado adecuado de explotación podría ser prevenido, resultando en un convergencia lenta y por lo tanto soluciones de baja calidad. Por esta razón, Mahfoud [5] utilizó el concepto de diversidad útil, con cual se refiere a la cantidad de diversidad que resulta en soluciones de alta calidad. En la literatura existen distintas formas para aliviar el problema de convergencia prematura [6]. En los 90s, la mayoría de estrategias para aliviar la convergencia prematura se centraron en modificar el esquema de selección de padres. La principal razón es que en esa época la mayoría de esquemas eran generacionales, por lo tanto la presión de selección estaba definida principalmente en la selección de padres. Sin embargo, se descubrió que tratando de aliviar la convergencia prematura donde únicamente sea considerada la selección de padres no fue suficiente [7]. Posteriormente, la una gran cantidad de EAs incorporaron una fase de reemplazo que abandonaron al menos parcialmente a los métodos generacionales iniciales. Basado en esto muchos autores descubrieron la posibilidad de incorporar métodos para aliviar el problema de convergencia prematura [4]. Es importante considerar que aún cuando los métodos de reemplazamiento generacionales [8] fueron suficientemente populares, algunos autores ya habían tomado en cuenta esta estrategia [9]. Sin embargo, con la efectividad de elitismo y otras estrategias de reemplazo, el número de esquemas que adoptaron estos principios crecieron de forma considerable [10].

Un aspecto importante de la convergencia prematura es que depende completamente de la cantidad de tiempo y/o generaciones asignados a las ejecuciones del EA, es decir el criterio de paro. En su lugar, un EA debería ser ejecutado para resolver un problema dado por un tiempo definido y éste debería proporcionar soluciones prometedoras. A pesar de esto, es sorprendente que la mayoría de métodos que se han propuesto para aliviar la desventaja de la convergencia prematura no consideran el criterio de paro el cual es asignado por el usuario para alterar su comportamiento interno. Esto significa que, dependiendo en el criterio de paro, distintas parametrizaciones podrían ser requeridas. Como resultado, para criterio de paro distinto, el usuario debería estudiar el efecto de distintos parámetros. Un ejemplo popular de esto es *El Torneo de Selección Restringida (TSR)* [4], este método retrasa la convergencia de los EAs. Específicamente, este método incorpora un parámetro que puede ser utilizado para alterar el balanceo entre exploración e intensificación. Sin embargo, la pérdida de diversidad y posteriormente el balanceo entre exploración e intensificación no dependen únicamente en este parámetro, por lo tanto distintos valores deberían ser utilizados para cada problema y además para cada criterio de paro. El principio básico de las técnicas para la preservación de la diversidad y que afectan a la fase de reemplazo se basa en que el efecto de diversificar a los sobrevivientes induce un mayor grado de exploración. Esto se debe a varios aspectos importantes, principalmente una población grande mantiene varias regiones del espacio de búsqueda. Además los operadores

de cruce tienden a ser más explorativos cuando están involucrados individuos distantes [11].

Entre las distintas categorías de EAs, Evolución Diferencial (Differential Evolution - DE) es una de las estrategias más efectivas para lidiar con problemas de optimización continua [12]. De hecho, esta categoría de algoritmos han sido los ganadores en varias competencias de optimización [13]. Similarmente a otros EAs, DE está inspirado en el proceso de evolución natural, y además involucra la aplicación de mutación, recombinación y selección. La principal característica de DE es que éste considera las diferencias de los vectores que están presentes en la población con el motivo de explorar el espacio de búsqueda. En este sentido DE es similar a los optimizadores *Nelder-Mead* [14] y a la *Búsqueda Aleatoria Controlada (BAC)* [15]. A pesar de la efectividad de DE, existen varias debilidades que han sido detectadas y resueltas de forma parcial que por lo tanto han generado extensiones a la variante estándar de DE [13]. Algunos de los problemas más conocidos es la sensibilidad de la parametrización [16], la apariencia de estancamiento debido a las capacidades de exploración reducidas [17, 18] y la convergencia prematura [19]. Desde la aparición de DE, varias críticas se hicieron debido a su falta de capacidad para mantener un grado de diversidad suficiente dado a la elevada presión de selección [17]. Por lo tanto, se han generado varias extensiones de DE para aliviar la convergencia prematura, como la adaptación de parámetros [19], auto-adaptación de la diversidad en la población [20] y estrategias de selección con una menor presión de selección [17]. Algunos de los últimos estudios en el diseño metaheurísticas poblacionales [4] mostraron que controlando explícitamente la diversidad es particularmente útil para obtener un propio balanceo entre el grado de exploración y de intensificación. Nuestra hipótesis es que introduciendo un mecanismo para la preservación de la diversidad results en un balanceo adecuado entre exploración e intensificación, que a su vez propociona soluciones de alta calidad en ejecuciones a largo plazo.

Principalmente en este capítulo se explican dos propuestas, primeramente DE con Mantenimiento de Diversidad Mejorado (DE with Enhanced Diversity Maintenance DE-EDM), el cual integra un principio similar en DE y el operador Dinámico basado en el Cruce Binario Simulado (Dynamic Simulated Binary Crossover DSBX).

Our novel proposal, which is called DE with Enhanced Diversity Maintenance (DE-EDM), integrates a similar principle into DE. El resto de este capítulo está organizado de la siguiente forma.

2. Diseño de Evolución Diferencial basado en diversidad

2.1. Evolución Diferencia: Conceptos Básicos

Esta sección esta dedicada para repasar la variante clásica de DE y para introducir algunos de los mas importantes términos utilizados en el campo de DE. El clásico esquema DE es identificado como DE/rand/1/bin el cual ha sido

extensamente utilizado para generar más variantes complejas [13]. De hecho, nuestra propuesta también extiende a la clásica versión DE. Originalmente DE fue propuesta como un método de búsqueda directo para optimización continua mono-objetivo. El conjunto de variables involucradas en el planteamiento de un problema son dados como un vector de la forma $\mathbf{X} = [x_1, x_2, \dots, x_D]$, donde D es la dimensión del problema. En optimización continua, cada x_i es un número real, además son proporcionadas restricciones de caja, es decir, existe un límite inferior (a_i) y un límite superior (b_i) para cada variable. El objetivo de un proceso de optimización es obtener un vector \mathbf{X}^* el cual minimiza una función objetivo dada, esto matemáticamente es definido por $f : \Omega \subseteq \mathbb{R}^D \rightarrow \mathbb{R}$. En el caso de la restricción de caja $\Omega = \prod_{j=1}^D [a_j, b_j]$.

DE es un algoritmo estocástico basado en una población, por lo tanto éste involucra iterativamente a un conjunto de soluciones candidatas. En DE dichas soluciones candidatas son usualmente conocidas como vectores. En la variante básica de DE, para cada miembro de la población conocidos como *vectores objetivo* es generado un nuevo vector conocido como *vector mutado*. Entonces, el vector mutado es combinado con el vector objetivo para generar al *vector de prueba*. Finalmente, una fase de selección es aplicada para seleccionar a los vectores sobrevivientes. De esta forma, transcurren las generaciones hasta cumplir el criterio de paro. El i -ésimo vector de la población en la generación G es definido como $\mathbf{X}_{i,G} = [x_{1,i,G}, x_{2,i,G}, \dots, x_{D,i,G}]$. A continuación se explica en más detalle cada componente de DE.

2.1.1. Inicialización

DE usually starts the optimization process with a randomly initiated population of NP vectors. Since there is commonly no information about the performance of different regions, uniform random generators are usually applied. Hence, the j th component of the i th vector is initialized as $x_{j,i,0} = a_j + rand_{i,j}[0, 1](b_j - a_j)$, where $rand_{i,j}[0, 1]$ is an uniformly distributed random number lying between 0 and 1.

2.1.2. Mutación

Para cada vector objetivo un vector mutado es creado, varias estrategias para realizar este procedimiento han sido propuestas. En la variante clásica de DE se aplica la estrategia $rand/1$. En este caso, es creado el vector mutado $V_{i,G}$ de la siguiente forma:

$$\mathbf{V}_{i,G} = \mathbf{X}_{r1,G} + F \times (\mathbf{X}_{r2,G} - \mathbf{X}_{r3,G}) \quad r1 \neq r2 \neq r3 \quad (1)$$

Los índices $r1, r2, r3 \in [1, NP]$ distintos enteros seleccionados de forma aleatoria en el rango $[1, NP]$. Además, estos índices son distintos al índice i . Es importante tomar en cuenta que la diferencia entre los vectores es escalada por medio del parámetro F , el cual se define usualmente en el intervalo $[0, 4]$. La diferencia escalada es agregada al tercer vector, por lo tanto los vectores

mutados son similares a los vectores objetivo cuando el grado de diversidad es poco y las diferencias son pequeñas. Como resultado, es importante mantener un grado de diversidad mínimo en DE.

2.1.3. Cruza

En orden con el objetivo de combinar la información de distintas soluciones candidatas y con el propósito de incrementar la diversidad es aplicado el operador de cruce. Específicamente, cada vector objetivo $\mathbf{X}_{i,G}$ es mezclado con su correspondiente vector mutado $\mathbf{V}_{i,G}$ para generar un vector de prueba $\mathbf{U}_{i,G} = [u_{1,i,G}, u_{2,i,G}, \dots, u_{D,i,G}]$. La estrategia de cruce mas típica es conocida como cruce *binomial*, el cual funciona de la siguiente forma:

$$\mathbf{U}_{j,i,G} = \begin{cases} \mathbf{V}_{j,i,G}, & \text{si } (rand_{i,j}[0, 1] \leq CR \text{ or } j = j_{rand}) \\ \mathbf{X}_{j,i,G}, & \text{de otra forma} \end{cases} \quad (2)$$

donde $rand_{i,j}[0, 1]$ es un número uniformemente distribuido, j_{rand} es un índice aleatoriamente seleccionado el cual asegura que $\mathbf{U}_{i,G}$ genera al menos un componente de $\mathbf{V}_{i,G}$ y $CR \in [0, 1]$ es la razón de cruce.

2.1.4. Selección

Finalmente, se aplica una selección glotona para determinar a los sobrevivientes de la siguiente generación. Cada vector de prueba es comparado con su correspondiente vector objetivo y el mejor es el que sobrevive:

$$\mathbf{X}_{j,i,G+1} = \begin{cases} \mathbf{U}_{i,G}, & \text{si } f(\mathbf{U}_{i,G}) \leq f(\mathbf{X}_{i,G}) \\ \mathbf{X}_{i,G}, & \text{de otra forma} \end{cases} \quad (3)$$

Hence, each population member either gets better or remains with the same objective value in each generation. Since members never deteriorate, it is considered to be a selection with high pressure. Note that in case of a tie, the trial vector survives.

2.2. Diversidad en Evolución Diferencial

Los algoritmos basados en DE son altamente susceptibles a la pérdida de diversidad debido a la estrategia de selección agresiva. Sin embargo, se han desarrollado varios análisis para lidiar con este problema. Desde que se conocen las implicaciones de cada parámetro en la diversidad, una alternativa es la estimación teórica de los valores adecuados en DE [19]. Alternativamente, se han desarrollado algunos análisis donde es considerado el efecto de los vectores de diferencia en la mutación [21]. Estos análisis y otros estudios empíricos basados en la cruce permitieron concluir que ciertos tipos de movimientos deberían ser deshabilitados para retrasar la convergencia [22]. En este último estudio varía el tipo de movimientos aceptados a lo largo de la ejecución.

Específicamente, esto descarta movimientos menores a un umbral el cual es decrementado conforme transcurren las generaciones. Se han propuesto otras formas de alterar el procedimiento en que se aceptan los movimientos [23]. Es importante notar que este tipo de métodos tienen similitudes con nuestra propuesta en el sentido de que las decisiones están basadas por el número de generaciones transcurridas. Sin embargo, nuestro método opera en la estrategia de reemplazo y no en la fase de mutación. Mas aún, estos métodos no consideran de forma explícita las diferencias que aparecen en la población entera. En su lugar, las restricciones son aplicadas a las diferencias que aparecen en la fase de reemplazo.

Una alternativa distinta reside en alterar el operador de selección [17]. Particularmente, se relaja la presión de selección a través de una selección probabilística con el propósito de mantener la diversidad en la población y consecuentemente permitir escapar de la base de atracción de un óptimo local. Sin embargo este método es muy sensible a transformaciones desde que esta estrategia considera la aptitud para definir las probabilidades para aceptar un individuo mutado. En este caso las decisiones no se basan en las generaciones transcurridas.

Finalmente, en el algoritmo *Diversidad de la Población Auto-Mejorado* (*Auto-Enhanced Population Diversity* - AEPD), la diversidad es explícitamente medida y esto es un disparo a un mecanismo para diversificar a la población cuando se detecta poca diversidad en la población [20]. También ya se han propuesto estrategias con principios similares pero con esquemas de perturbación distintos.

Es importante notar que las mejores variantes-DE de las competencias no utilizan estas modificaciones y que la mayoría de estas extensiones no han sido implementadas en los herramientas de optimización más utilizadas. Como resultado, estas extensiones no son ampliamente utilizadas por la comunidad a pesar de sus beneficios en ciertos casos.

2.3. Propuesta

Nuestra propuesta está motivada por dos trabajos significativos de ésta área cuyo propósito es el control de la diversidad en los EAs. Por su parte el primero es un estudio empírico desarrollado por Montgomery y otros [22], este trabajo presenta varios análisis empíricos los cuales confirman los problemas relacionados con la convergencia prematura.

Por otro lado, el segundo trabajo propuesto por Segura [24] y otros, proporciona mejoras significativas en el campo optimización combinatoria, en esta propuesta se desarrolla una novel estrategia de reemplazo nombrada *Reemplazo con Control de Diversidad Dinámico Basado en Varios Objetivos* (*Replacement with Multi-objective based Dynamic Diversity Control* - RMDDC) donde se controla el grado de diversidad con el criterio de paro y las generaciones transcurridas. Se obtuvieron beneficios por los métodos que incluyeron el RMDDC, por lo tanto y basados en las conclusiones de los trabajos previos,

Algorithm 1 Esquema general del DE-EDM

```

1: Inicializar de forma aleatoria a la población con  $NP$  individuos, donde cada uno es distribuido
   de forma uniforme.
2:  $G = 0$ 
3: while El criterio de paro no sea alcanzado do
4:   for  $i = 1$  to  $NP$  do
5:     Mutación: Generar al vector mutado ( $V_{i,G}$ ) de acuerdo a la ecuación (1).
6:     Cruza: Utilizar la recombinación para generar al vector de prueba ( $U_{i,G}$ ) de acuerdo a
       la ecuación (2).
7:     Selección: Actualizar al vector elite ( $E_{i,G}$  en lugar de  $X_{i,G}$ ) de acuerdo a la ecuación
       (3).
8:   Reemplazo: Seleccionar a los vectores objetivo ( $X_{G+1}$ ) de acuerdo a la ecuación (2).
9:    $G = G + 1$ 

```

la propuesta de esta sección es una novel variante de DE que incluye un mecanismo explícito el cual sigue uno de los principios del RMDDC. Este novel optimizador es nombrado *Evolución Diferencial con Mantinimiento Mejorado de Diversidad* (Differential Evolution with Enhanced Diversity Maintenance - DE-EDM) y su código fuente está disponible de forma gratuita ¹

La esencia de DE-EDM (ver algoritmo 1) es suficiente similar a la versión estándar de DE. De hecho la forma en que se crean los vectores de prueba no es modificado de forma significativa (líneas 5 y 6). La novedad de la propuesta es que incorpora una población elite (E) y una novel estrategia de reemplazo basada en la diversidad. En orden, para seleccionar a los miembros de la población, se aplica el reemplazo agresivo (glotón) de la versión original de DE (línea 7). Por otra parte, se considera otra estrategia de reemplazo (línea 8), la cual realiza la selección de los miembros que participarán en el siguiente procedimiento de selección, esto se realiza siguiendo el mismo principio que el RMDDC, es decir los individuos que contribuyen muy poco a la diversidad no deberán ser aceptados como miembros en la siguiente generación. En este sentido, no se utiliza la misma estrategia de selección agresiva que pertenece a DE para mantener a la población padre (X). En este orden para establecer una contribución aceptable de diversidad mínima para realizar la selección, son tomados en cuenta el criterio de paro y las generaciones transcurridas. Una de las principales debilidades del RMDDC es que su convergencia se retrasa de forma significativa. Por lo tanto, se realizan dos modificaciones al RMDDC para promover una convergencia acelerada. Primero, no son considerados los conceptos multi-objetivo, en su lugar se considera una selección mas agresiva. Segundo, también es considerada la población elite en la estrategia de reemplazo.

Nuestra estrategia de reemplazo (ver Algoritmo 2) funciona de la siguiente forma. Éste recibe a la población padre (vectores objetivo), la población de hijos (vectores de prueba) y a los vectores elite. En cada generación son seleccionados NP vectores para la siguiente población de padres. Primero, en base al número de evaluaciones a función (línea 2) es calculada una distancia mínima D_t deseada para mantener la diversidad. Entonces, son juntadas las tres poblaciones en un conjunto de miembros candidatos (línea 3). El conjunto

¹ El código en C++ puede ser descargado en la siguiente dirección https://github.com/joelchaconcastillo/Diversity_DE_Research.git

Algorithm 2 Fase de Reemplazo

```

1: Entrada: Población (Vectores Objetivo), Hijos (Vectores de prueba), y Elite
2: Actualizar  $D_t = D_I - D_I * (nfes / (0.95 * max.nfes))$ 
3:  $Candidatos = Población \cup Hijos \cup Elite$ .
4:  $Sobrevivientes = Penalizados \emptyset$ .
5: while  $Sobrevivientes < NP$  y  $|Candidatos| > 0$  do
6:    $Seleccionados =$  Seleccionar al mejor individuo de Candidatos.
7:   Eliminar Seleccionado de Candidatos.
8:   Copias Seleccionado a Sobrevivientes.
9:   Encontrar los individuos de Candidatos cuya distancia a Seleccionados sea menor que  $D_t$ 
      y moverlos al Penalizados. En esta parte se considera la distancia normalizada (Ecuación
      4).
10: while  $|Sobrevivientes| < NP$  do
11:    $Seleccionado =$  Seleccionar al individuo de Penalizados con la mayor distancia al individuo
      mas cercano a Sobrevivientes.
12:   Eliminar Seleccionado de Penalizados.
13:   Copiar Seleccionado a Sobrevivientes
14: return Survivors

```

de miembros candidatos continen vectores que podrían ser seleccionados para sobrevivir. Entonces, el conjunto de individuos sobrevivientes y penalizados son inicializados por el conjunto vacío (línea 4). En orden para seleccionar a los NP sobreviviente (población padre de la siguiente generación) se repite un procedo iterativo (líneas 5 - 13). En cada paso es seleccionado el mejor individuo para sobrevivir del *Conjunto de Candidatos*, es decir al individuo que tiene la mejor aptitud, entonces es movido al *Conjunto de Sobrevivientes*. Entonces, los individuos que pertenecen al *Conjunto de Candidatos* cuya métrica de mínima distancia sea menor que D_t son transferidos *Conjunto de Penalizados* (línea 9).

La forma para calcular la distancia entre dos individuos es en base a la distancia Euclideana normalizada descrita en la ecuación 4, donde D es la dimensión del problema, y a_d, b_d son los límites menores y mayores de cada dimensión (d). En los casos donde *El conjunto de Candidatos* está vacío previamente a la selección de los NP individuos, el *Conjunto de Sobrevivientes* se llena seleccionando en cada iteración al individuo *Penalizado* con la mayor distancia al individuo más cercano al *Conjunto de Sobrevivientes* (líneas 10 - 13).

$$distance(x_i, x_j) = \frac{\sqrt{\sum_{d=1}^D \left(\frac{x_i^d - x_j^d}{b_d - a_d} \right)^2}}{\sqrt{D}} \quad (4)$$

En este orden con el propósito de completar la descripción es importante especificar la forma en que se calcula D_t y el para actualizar a los individuos elite. El resto del algoritmo es mantenido de igual forma que la clásica variante de DE. El valor de D_t es utilizado para alterar el grado entre exploración y explotación, por lo tanto éste parámetro debería depender en la etapa de optimización. Específicamente, este valor debería ser reducido conforme se alcanza el criterio de paro con el objetivo de promover un grado de intensificación. En nuestro esquema se requiere asignar un valor inicial para D_t (D_I). Así, similarmente que en [24], se calcula una reducción lineal de D_t considerando las

evoluciones a función y el criterio de paro. Particularmente, en este trabajo, el criterio de paro es asigna en base a las evaluaciones a función. La reducción es calculada de tal forma que en el 95 % del máximo número de evaluaciones a función el valor de D_t es 0. Por lo tanto, la diversidad no es considerada del todo en el restante 5 %. Entonces, si max_n_fes es el máximo número de evaluaciones y n_fes es el número de evaluaciones transcurridas n_fes , entonces D_t puede ser calculado de la siguiente forma $D_t = D_I - D_I * (n_fes / (0,95 * max_n_fes))$.

La distancia inicial (D_I) afecta de forma considerable al rendimiento del DE-EDM. Si este parámetro es elevado, entonces el algoritmo tiene como objetivo maximizar la diversidad de la población en las primeras etapas de optimización, por lo tanto se genera una exploración adecuada la cual es muy importante, particularmente en varios tipos de problemas tales como altamente multi-modales y deceptivos. Entonces, se podría aliviar el efecto de la convergencia prematura. Un valor muy elevado de D_I podría inducir exploración excesivamente y por lo tanto una fase de intensificación podría no ser no es efectuada. Por otra parte, un valor muy pequeño de D_I podría evitar la fase de exploración, por lo tanto será más difícil evitar óptimos locales. El óptimo D_I podría variar dependiendo en el tipo problema y el criterio de paro. En su lugar, los problemas deceptivos y altamente multi-modales usualmente requieren valores más elevados que en los problemas unimodales. Sin embargo, en nuestra propuesta no se adapta un valor D_I para cada problema, por lo tanto con el propósito de analizar la estabilidad de este parámetro se realiza un análisis con diferentes valores de D_I en la sección de validación experimental.

Al igual que a la versión estándar DE, en nuestra propuesta DE-EDM se debe asignar una probabilidad de cruce (CR) y un factor de mutación (F).

El primero es quizás es más importante de acuerdo a varios estudios desarrollados por Montgomery y otros [25]. Estos autores probaron de forma empírica que valores extremos de CR resultan en un comportamiento muy distinto. Ellos explicaron que bajos valores de CR resultan en una búsqueda que es alineada con un pequeño número de ejes y además induce pequeños desplazamientos. Esto provoca una convergencia lenta y gradual que en algunos escenarios podría provocar un comportamiento robusto. Adicionalmente, valores elevados de CR podrían generar soluciones de mayor calidad con una menor probabilidad. Sin embargo, estas transformaciones provocan largos desplazamientos que podrían mejorar de forma significativa. De acuerdo a esto, en nuestra propuesta se emplean los dos principios, es decir, valores elevados y pequeños de CR como es mostrado en la ecuación 5.

$$CR = \begin{cases} Normal(0,2,0,1), & \text{si } rand[0,1] \leq 0,5 \\ Normal(0,9,0,1), & \text{de otra forma} \end{cases} \quad (5)$$

Siguiendo los principios de distintas variantes del SHADE [26,27], se consideran las evaluaciones a función en el proceso de generación aleatorio del factor de mutación F . Particularmente, cada valor F es una muestra de una distribución Cauchy (Ecuación6).

$$Cauchy(0,5,0,5 * n_fes / max_n_fes) \quad (6)$$

Por lo tanto, en las primeras etapas de optimización los valores de F son generados de forma cercana a 0,5. Conforme la ejecución transcurre, la función de densidad sufre una transformación gradual donde la varianza se incrementa, esto implica que son generados valores fuera del intervalo $[0,0,1,0]$ con una probabilidad alta. En los casos cuando los valores son mayores a 1,0, es utilizado un valor de 1,0. Si se genera un valor negativo, entonces este valor se vuelve a generar. Uno de los efectos de este enfoque es incrementar la probabilidad de generar valores elevados de F conforme transcurren las generaciones con el objetivo de evitar una convergencia en las últimas etapas de optimización.

2.4. Resultados

En esta sección se presenta la validación experimental. Especialmente, demostramos que los resultados de los algoritmos que pertenecen al estado-del-arte pueden ser mejorados controlando explícitamente la diversidad en el clásico DE. Particularmente, se consideraron los conjuntos de prueba del CEC 2016 y CEC 2017. Cada uno está compuesto de treinta distintos problemas. El estado-del-arte está compuesto por los algoritmos que alcanzaron los primeros lugares en cada año. Adicionalmente, se incluyó la versión estándar DE. Por lo tanto, los algoritmos considerados del CEC 2016 son el UMOEAs-II [28] y L-SHADE-EpSin [26], los cuales alcanzaron el primero y el segundo lugar respectivamente. Similarmente, los mejores algoritmos del CEC 2017 son el EBOwithCMAR [29] y el jSO [30].

Es importante destacar que el EBOwithCMAR es considerado como una mejora del UMOEAs-II. Adicionalmente, el jSO y el L-SHADE-EpSin pertenecen a la familia de SHADE. Todos estos algoritmos fueron probados con los dos conjuntos de prueba como es sugerido en [31]. Debido a que todos los algoritmos son estocásticos se realizaron 51 ejecuciones con distintas semillas.

En cada caso, el criterio de paso fue asignado a 25,000,000 evaluaciones a función. La evaluación de los algoritmos se realizó siguiendo los lineamientos de las competencias del CEC. Entonces, se asignó un error de 0 si la diferencia entre la mejor solución encontrada y la solución óptima era menor que 10^{-8} . Para cada algoritmo se utilizó la parametrización indicada por los respectivos autores, que son definidos a continuación:

- **EBOwithCMAR:** Para la parte EBO, el tamaño máximo de la población de $S_1 = 18D$, el tamaño mínimo de la población de $S_1 = 4$, el tamaño máximo de la población de $S_2 = 146,8D$, el tamaño mínimo de la población de $S_2 = 10$, el tamaño de la memoria histórica $H=6$. Para la parte de CMAR el tamaño de la población $S_3 = 4 + 3\log(D)$, $\sigma = 0,3$, $CS = 50$, la probabilidad de búsqueda local $pl = 0,1$ y $cfe_{ls} = 0,4 * FE_{max}$.
- **UMOEAs-II:** Para la parte de MODE, el tamaño máximo de la población de $S_1 = 18D$, el tamaño mínimo de la población de $S_1 = 4$, el tamaño de la memoria histórica $H=6$. Para la parte del CMA-ES el tamaño de la población $S_2 = 4 + \lfloor 3\log(D) \rfloor$, $\mu = \frac{PS}{2}$, $\sigma = 0,3$, $CS = 50$. Para la búsqueda local, $cfe_{ls} = 0,2 * FE_{max}$.

- **jSO**: El tamaño máximo de la población $= 25\log(D)\sqrt{D}$, el tamaño de la memoria histórica $H = 5$, valor de mutación inicial de la memoria $M_F = 0,5$, probabilidad inicial de la memoria $M_{CR} = 0,8$, tamaño mínimo de la población $= 4$, valor inicial p-best $= 0,25 * N$, valor final p-best $= 2$.
- **L-SHADE-EpSin**: Tamaño máximo de la población $= 25\log(D)\sqrt{D}$, tamaño de la memoria histórica $H = 5$, valor de la mutación inicial de la memoria $M_F = 0,5$, probabilidad inicial de la memoria $M_{CR} = 0,5$, frecuencia inicial de la memoria $\mu_F = 0,5$, tamaño mínimo de la población $= 4$, valor inicial p-best $= 0,25 * N$, valor final p-best $= 2$, generaciones de la búsqueda local $G_{LS} = 250$.
- **DE-EDM**: $D_I = 0,3$, tamaño de la población $= 250$.
- **Standard-DE**: tamaño de la población $= 250$ (mismos operadores que en DE-EDM).

Nuestro análisis experimental se desarrolló en base a la diferencia entre la solución óptima y la mejor solución obtenida. En orden para comparar los resultados estadísticamente, se siguió un procedimiento similar que el propuesto en [32].

Concretamente, en primer lugar se utilizó el test Shapiro-Wilk para comprobar si los resultados se ajustaban a una distribución Gaussiana. En los casos en que sí se ajustaban, se utilizó el test de Levene para comprobar la homogeneidad de las varianzas, procediendo con el test de ANOVA en caso positivo o con el de Welch en caso negativo. Por otro lado, para los casos que no se ajustaban a distribuciones Gaussianas, se utilizó el test de Kruskal-Wallis. En todos los casos se fijó el nivel de confianza al 95 %. Se considera que un algoritmo X es superior a un algoritmo Y , si el procedimiento anterior reporta diferencias significativas y si la media y mediana del hipervolumen obtenido por el método X son superiores a las obtenidas por el método Y . En las tablas 1 y 2 se presenta un resumen de los resultados obtenidos para el CEC 2016 y el CEC 2017 respectivamente. La columna etiquetada con “Simpre Resuelto” muestra el número de funciones en que se obtuvo un error de cero en las 51 ejecuciones. Adicionalmente, la columna etiquetada con “Al menos una vez resuelto” muestra el número de soluciones que se resolvieron en al menos una ejecución. Practicamente nuestra propuesta resolvió al menos una vez todas las funciones (28 funciones) que pertenecen al conjunto de problemas del CEC 2017. Adicionalmente, fueron resueltas al menos una vez 21 funciones que pertenecen al CEC 2016. Esta es una diferencia sustancial con los resultados obtenidos por los algoritmos que pertenecen al el estado-del-arte. Estos algoritmos obtuvieron los valores óptimos significativamente en menos funciones. En orden para confirmar la superioridad del DE-EDM, se implementaron las pruebas estadísticas por pares. La columna etiquetada con el símbolo \uparrow muestra que el número de veces en que cada método fue superior, mientras que la columna etiquetada con \downarrow cuenta el número de casos donde el método fue inferior. Finalmente, la columna etiquetada con \longleftrightarrow muestra el número de comparaciones cuyas diferencias no fueron significativas. Las pruebas estadísticas indican que el DE-EDM alcanzó los mejores resultados en los

dos años. De hecho el número de veces en que nuestra propuesta ganó en el CEC 2016 y el CEC 2017 fue de 77 y 88 respectivamente. Además el número de veces en que perdió fueron de 25 y 6 respectivamente. Adicionalmente, el último lugar alcanzado en los dos años fue por el algoritmo L-SHADE-Epsilon con 20 comparaciones positivas en el 2016 y 7 comparaciones positivas en el 2017. La última columna etiquetada con “Puntaje” muestra un análisis que fue propuesto en las competencias del CEC. Particularmente, este método de evaluación combina dos puntajes como se indica en la ecuación (7). Por lo tanto el puntaje final está compuesto por la suma $Score = Score_1 + Score_2$.

$$\begin{aligned} Score_1 &= \left(1 - \frac{SE - SE_{min}}{SE}\right) \times 50, \\ Score_2 &= \left(1 - \frac{SR - SR_{min}}{SR}\right) \times 50, \end{aligned} \quad (7)$$

donde, SE_{min} es la suma mínima de errores entre todos los algoritmos, y SE es la suma de errores dado un algoritmo $SE = \sum_{i=1}^{30} error_f_i$. Similarmente, SR_{min} es la suma mínima de los rangos entre todos los algoritmos, específicamente es la suma de cada rango en cada función para los algoritmos considerados $SE = \sum_{i=1}^{30} error_f_i$. Principalmente, nuestra propuesta alcanzó los mejores puntajes (100,00) en los dos años, demostrando su superioridad. Adicionalmente, la versión estándar de DE alcanzó resultados suficientemente buenos, de hecho obtuvo el tercer y el segundo lugar en los años 2016 y 2017 respectivamente. Esto muestra que el rendimiento de los algoritmos en el estado-del-arte es distinto al considerar ejecuciones a largo plazo. El algoritmo L-SHADE-Epsilon obtuvo un puntaje competitivo a pesar de que en el CEC del 2017 alcanzó el menor número de comparaciones positivas dentro de las pruebas estadísticas. Esto podría ocurrir desde que los puntajes estadísticos consideran la media y mediana de los errores. Es más el puntaje considera el rango y la media basado en el error.

Dado que nuestra propuesta está basada en el control explícito de la diversidad y con el objetivo de entender mejor su comportamiento, en la figura 1 se muestra la evolución de la diversidad a través de las evaluaciones a función. Particularmente, se ejecutó el DE-EDM con las funciones F_1 y f_{30} . Basado en sus propiedades la primera función se resuelve de forma sencilla (unimodal) y la segunda función es considerada como una de las más difíciles (híbrida). En la parte izquierda se muestra la diversidad que se mantiene en la población Elite. A pesar de que existen mecanismos para evitar la pérdida de diversidad en la población Elite, se puede observar que se mantiene un grado de diversidad de forma implícito en las dos funciones. Similarmente, la parte derecha corresponde a la diversidad de los vectores de prueba. Esto demuestra que se demuestra un grado de diversidad de forma explícito, es decir hasta el 95 % del total de evaluaciones a función.

En orden, con el fin de proporcionar resultados comparables, en las tablas 3 y 4 se reporta el mejor, peor, mediana, media, desviación estándar y

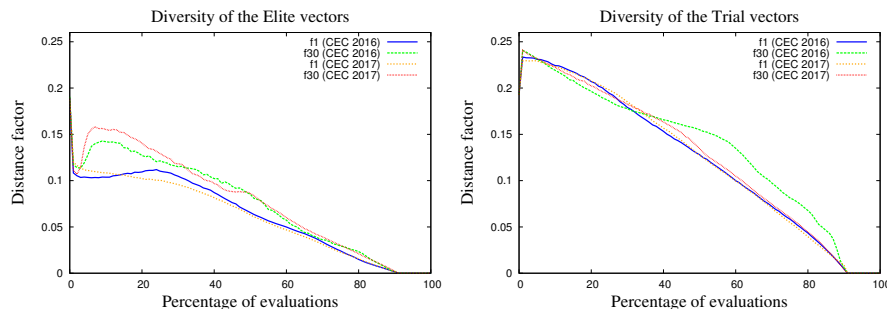


Figura 1 Promedio del DCN de las 51 ejecuciones con los problemas f_1 y f_{30} (CEC 2016 y CEC 2017). El factor de distancia inicial corresponde a $D_I = 0,3$.

Cuadro 1 Resumen de los resultados - CEC 2016

Algorithm	Siempre Resuelto	Resuelto al menos una vez	Pruebas Estadísticas			Puntaje
			↑	↓	↔	
EBOwithCMAR	8	14	35	56	59	50.28
jSO	9	17	47	51	52	55.43
UMOEAs-II	9	14	51	31	68	62.45
L-SHADE-Epsilon	7	13	20	71	59	50.12
DE-EDM	13	21	77	25	48	100.00
Standard-DE	11	19	50	46	54	56.29

Cuadro 2 Resumen de los resultados - CEC 2017

Algorithm	Siempre Resuelto	Resuelto al menos una vez	Pruebas Estadísticas			Puntaje
			↑	↓	↔	
EBOwithCMAR	9	18	34	46	70	37.14
jSO	8	15	29	55	66	29.30
UMOEAs-II	11	15	43	40	67	26.89
L-SHADE-Epsilon	8	19	7	81	62	32.78
DE-EDM	21	28	88	6	56	100.00
Standard-DE	12	21	56	29	65	42.91

razón de éxito. Particularmente, en estas tablas se observa que nuestra propuesta resuelve a todos los problemas unimodales. Además, varias funciones multimodales son aproximadas de forma aceptable. Principalmente, nuestra propuesta resolvió y mejoró significativamente varias funciones complejas (por ejemplo funciones computestas), que por otra parte no fueron resueltas por los algoritmos del estado-del-arte.

2.5. Análisis Empírico del factor de distancia inicial

En nuestra propuesta la diversidad es explícitamente promovida a través de varias etapas, y son promovidas por medio del factor de distancia inicial D_I . Por lo tanto, se analiza en detalle el efecto de este parámetro. Particularmente, se considera la configuración general de la validación experi-

Cuadro 3 Resultados del DE-EDM con los problemas del CEC 2016

	Mejor	Peor	Mediana	Media	Sd	Razón de éxito
f_1	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_2	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_3	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_4	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_5	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_6	0.00E+00	3.60E-02	4.00E-03	7.39E-03	1.15E-02	3.92E-01
f_7	2.00E-02	1.02E-01	5.90E-02	5.77E-02	4.93E-02	0.00E+00
f_8	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_9	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{10}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{11}	0.00E+00	6.00E-02	0.00E+00	5.88E-03	1.90E-02	9.02E-01
f_{12}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{13}	1.00E-02	8.00E-02	5.00E-02	4.67E-02	2.60E-02	0.00E+00
f_{14}	1.00E-02	5.00E-02	3.00E-02	2.82E-02	2.13E-02	0.00E+00
f_{15}	0.00E+00	4.70E-01	2.20E-01	1.99E-01	1.55E-01	1.96E-02
f_{16}	4.00E-02	1.50E-01	8.00E-02	8.47E-02	4.96E-02	0.00E+00
f_{17}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{18}	0.00E+00	2.00E-02	1.00E-02	7.65E-03	6.32E-03	3.14E-01
f_{19}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{20}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{21}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{22}	0.00E+00	3.00E-02	0.00E+00	3.73E-03	2.76E-02	7.65E-01
f_{23}	0.00E+00	1.00E+02	0.00E+00	2.55E+01	5.10E+01	7.45E-01
f_{24}	0.00E+00	6.90E-01	0.00E+00	2.61E-02	1.33E-01	9.61E-01
f_{25}	1.00E+02	1.00E+02	1.00E+02	1.00E+02	0.00E+00	0.00E+00
f_{26}	8.00E-02	1.00E+02	5.29E+01	5.20E+01	3.19E+01	0.00E+00
f_{27}	2.50E-01	9.10E-01	5.40E-01	5.60E-01	2.92E-01	0.00E+00
f_{28}	0.00E+00	3.57E+02	3.43E+02	2.76E+02	1.60E+02	1.96E-01
f_{29}	1.00E+02	1.00E+02	1.00E+02	1.00E+02	0.00E+00	0.00E+00
f_{30}	1.84E+02	1.84E+02	1.84E+02	1.84E+02	3.25E-02	0.00E+00

mental. Entonces, se consideraron varios factores de distancia inicial ($D_I = \{0,0, 0,1, 0,2, 0,3, 0,4, 0,5, 0,6, 0,7, 0,8, 0,9, 1,0, 1,1\}$).

En la figura 2 se muestra la razón de éxito promedio vs. el factor de distancia inicial (D_I). Principalmente se puede observar lo siguiente:

- Si la diversidad no es promovida ($D_I = 0,0$) entonces el rendimiento del algoritmo está comprometido.
- En este escenario la configuración ideal es de $D_I = 0,3$, a pesar de que aún existen soluciones de calidad en el rango $[0,1, 0,4]$.
- Si se incrementa la diversidad inicial entonces se observa un deterioro en la calidad de las soluciones.

Finalmente, es importante aclarar que en base a varios estudios la calidad de las soluciones es afectado en un menor grado por el tamaño de la población que con el parámetro D_I .

3. Diseño de operadores de cruce basados en diversidad

Esta sección está destinada algunos de los trabajos mas importantes relacionados al ámbito de operadores de cruce y al concepto multi-objetivo. Primero, son definidos los paradigmas multi-objetivo mas importantes. Después

Cuadro 4 Resultados del DE-EDM con los problemas del CEC 2017

	Mejor	Peor	Mediana	Media	Sd	Razón de éxito
f_1	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_2	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_3	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_4	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_5	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_6	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_7	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_8	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_9	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{10}	0.00E+00	1.20E-01	0.00E+00	1.65E-02	3.39E-02	7.45E-01
f_{11}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{12}	0.00E+00	2.20E-01	0.00E+00	6.37E-02	1.76E-01	6.67E-01
f_{13}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{14}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{15}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{16}	0.00E+00	2.10E-01	0.00E+00	2.47E-02	7.27E-02	8.82E-01
f_{17}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{18}	0.00E+00	1.00E-02	0.00E+00	1.96E-03	4.47E-03	8.04E-01
f_{19}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{20}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{21}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{22}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{23}	0.00E+00	3.00E+02	0.00E+00	3.49E+01	1.03E+02	8.82E-01
f_{24}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{25}	0.00E+00	1.00E+02	0.00E+00	3.92E+00	2.00E+01	9.61E-01
f_{26}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{27}	0.00E+00	3.87E+02	3.87E+02	2.05E+02	2.68E+02	1.96E-02
f_{28}	0.00E+00	0.00E+00	0.00E+00	0.00E+00	0.00E+00	1.00E+00
f_{29}	1.45E+02	2.26E+02	2.18E+02	1.99E+02	4.21E+01	0.00E+00
f_{30}	3.95E+02	3.95E+02	3.95E+02	3.95E+02	2.10E-01	0.00E+00

de eso, se introducen algunas clasificaciones relevantes de los operadores de cruce. Finalmente, es discutido el operador de cruce SBX, el cual es utilizado de forma extensa en esta sección.

3.1. Algoritmos Evolutivos Multi-objetivo

En los últimos años, se han ideado una gran cantidad de MOEAs los cuales siguen distintos principios. En orden para mejor tener una mejor clasificación, se han propuesto varias taxonomías [33]. En base a sus principios de diseño, los MOEAs pueden ser basados en la dominancia de Pareto, indicadores y/o descomposición [34]. Todos estos algoritmos son suficientemente competitivos, por lo tanto en esta sección se consideraron MOEAs de distintos grupos. Particularmente, la validación experimental se desarrolló incluyendo a los algoritmos *Algoritmo Genético basado en Ordenación de los No-Dominados* (Non-Dominated Sorting Genetic Algorithm - NSGA-II) [35], *el MOEA basado en descomposición* (the MOEA based on Decomposition - MOEA/D) [36] y el *Algoritmo Evolutivo Multi-objetivo basado en la Métrica-S* (the S-Metric Selection Evolutionary Multi-objective Optimization Algorithm - SMS-EMOA) [37].) Estos algoritmos son representativos de los basados en dominancia, basados en descomposición y basados en indicadores respecti-

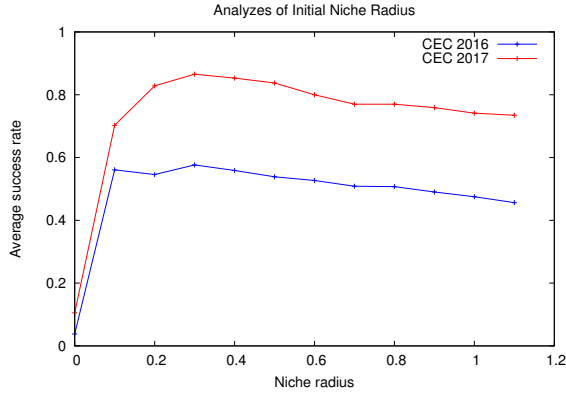


Figura 2 Razón de éxito promedio con distintos factores de distancia inicial con los problemas de prueba del CEC 2016 y CEC 2017, específicamente se considera una población de 250 individuos y 25,000,000 evaluaciones a función.

vamente. Las siguientes sub-secciones describen cada uno de los paradigmas involucrados en los métodos seleccionados.

3.1.1. Algoritmos Basados en el concepto de Dominancia - NSGA-II

Uno de los paradigmas mas reconocidos son los enfoques basados en dominancia. Los MOEAs que pertenecen a esta categoría se basan en la aplicación de la relación de dominancia para diseñar los distintos componentes de los mismos, especialmente en la fase de selección. Dado que la relación de dominancia no promueve la diversidad de forma implícita en el espacio de los objetivos se han desarrollado técnicas para obtener una diversidad en el espacio de los objetivos como es el niching, crowding y/o clustering que usualmente se integran. Una debilidad importante en los métodos basados en la relación de dominancia es la escalabilidad en términos de dimensionalidad en el espacio de los objetivos. De hecho la presión de selección es substancialmente reducida conforme el número de objetivos incrementan. A pesar de que se han desarrollado algunas estrategias para solventar este inconveniente [38], este parece ser la debilidad mas importante de este tipo de algoritmos.

El NSGA-II es uno de los algoritmos mas importantes de este grupo. Este algoritmo [35] considera un operador de selección especial el cual está basado en los procedimientos de la ordenación de las soluciones no dominadas y en el amontonamiento. El procedimiento que realiza la ordenación de las soluciones no dominadas es utiliza para proporcionar convergencia hacia el frente de Pareto mientras que el procedimiento de amontonamiento se utiliza para promover la diversidad en el espacio de los objetivos.

3.1.2. Algoritmos multi-objetivo basados en descomposición - MOEA/D

Los MOEAs basados en descomposición [36] transforman un MOP en un conjunto de problemas de optimización mono-objetivo de forma simultánea. Esta transformación puede ser lograda a través de distintos enfoques. Uno de los mas populares es por medio de la función pesada de Tchebycheff la cual requiere un conjunto de pesos bien distribuidos con el propósito de alcanzar soluciones bien distribuidas a lo largo del frente de Pareto. Sin embargo este tipo de algoritmos poseen una desventaja importante y está relacionada con la geometría que posee el frente de Pareto. El MOEA [36] es un MOEA popular de los basados en descomposición. Este incluye varias características, tales como la descomposición de los problemas, la agregación de los pesos con los objetivos y las restricciones de emparejamiento que están basadas en la definición de vecindarios. El algoritmo MOEA/D-DE es considerado como una variante popular del MOEA/D, el cual utiliza operadores de DE [39] y el operador de mutación polinomial [40] en la fase de reemplazo. Adicionalmente, este algoritmo tiene dos mecanismos especiales para mantener la diversidad de la población [41].

3.1.3. Algoritmo multi-objetivo basados en indicadores - SMS-EMOA

En optimización multi-objetivo se han desarrollado varios indicadores de calidad con el propósito de comparar el rendimiento de los MOEAs. Debido a que estos indicadores miden la calidad de las aproximaciones alcanzadas por los MOEAs se propuso un paradigma basado en la aplicación de estos indicadores. Particularmente, los indicadores reemplazan a la relación de dominancia de Pareto con el propósito de guiar el proceso de optimización. Principalmente, el hipervolumen es uno de los indicadores de calidad ampliamente aceptados denominado por su relación completa de Pareto (Pareto-compliance) [42]. Una de las principales ventajas de estos algoritmos es que los indicadores normalmente consideran tanto la calidad de las soluciones como su diversidad, por lo tanto no se requieren mecanismos adicionales para preservar la diversidad.

Un algoritmo popular que utiliza que es basado en indicadores es el SMS-EMOA [37]. Este MOEA es considerado como un algoritmo híbrido ya que utiliza tanto indicadores como el concepto de la dominancia de Pareto. Esencialmente, este algoritmo integra el procedimiento para ordenar a las soluciones no dominadas con la métrica del hipervolumen. Por lo tanto el SMS-EMOA aplica el hipervolumen como estimados de densidad siendo una tarea computacionalmente pesado. Particularmente, la fase de reemplazo elimina al individuo que pertenece al frente con peor rango y cuya contribución al hipervolumen sea mínima. Debido al comportamiento prometedor del SMS-EMOA se ha considerado como parte de nuestra validación experimental.




Figura 3 Probability density function of the SBX operator with indexes of distribution 2 and 5. The parents are located in 2 and 5 respectively.




Figura 4 Simulations of the SBX operator with a distribution index equal to 20. Parents are located in $P_1 = (-1,0,-1,0)$ and $P_2 = (1,0,1,0)$. The left simulation corresponds to a probability of altering a variable (δ_1 in Algorithm 3) equal to 1,0 and in the right it corresponds to 0,1.




Figura 5 Simulations of the SBX operator with a distribution index equal to 20. Parents are located in $P_1 = (-1,0,-1,0)$ and $P_2 = (1,0,1,0)$ and $P_1 = (-1,0,-1,0,-1,0)$ and $P_2 = (1,0,1,0,1,0)$ for two and three variables respectively.

3.2. Operadores de cruce

Los operadores de cruce son diseñados para generar soluciones hijo utilizando la información de las soluciones padre. Estos combinan las características de dos o más soluciones padre con el propósito de generar nuevas soluciones candidatas. En base a que en la literatura existen varios operadores de cruce se han propuesto varias taxonomías para clasificarlos. Particularmente, las taxonomías se basan en varias características tales como la ubicación de las nuevas soluciones generadas o por el tipo de relaciones que existen en las variables.

Una taxonomía popular realiza la clasificación de los operadores de cruce en basados en variables o basados en vectores. En la categoría donde son basados en las variables, cada variable de las soluciones padre son combinadas para crear nuevos valores, esto se realiza de forma independiente y en base

a una probabilidad especificada con anterioridad. Este tipo de operadores son ideales para lidiar con problemas separables. Algunos operadores que pertenecen a esta categoría son el *Operador de Cruce Ciego* (the Blend Crossover - BLX) [43] y el SBX [44]. De forma alternativa, los operadores de recombinación basados en vectores son diseñados para considerar la dependencia que existe entre las variables. Este tipo de operadores regularmente realizan una combinación lineal de las soluciones involucradas. Algunos operadores que pertenecen a esta categoría son *El Operador de Cruce Unimodal Normalmente Distribuido* (The Unimodal Normally Distributed Crossover - UNDX) [45], y *El Operador de Cruce basado en el Simplex* (The simplex crossover 'SPX) [46]. Adicionalmente, los operadores de cruce pueden ser clasificados como basados en los padres y basados en la media [47]. En los operadores basados en los padres, las soluciones hijo son creadas alrededor de cada solución padre, mientras que en los operadores basados en la media existen una tendencia de crear a las soluciones hijo alrededor de la media generada por las soluciones padres. Entre los operadores de cruce el SBX es probablemente uno de los más utilizados, por lo tanto esta sección se centra en este operador de cruce.

3.2.1. El Operador de Cruce Basado en Simulación Binaria - SBX

Los operadores de reproducción son uno de los componentes mas relevantes para influencias el proceso de búsqueda en los EAs. Específicamente, los operadores de cruce y mutación están altamente relacionados con la diversidad de las soluciones. Por lo tanto, los operadores considerados afectan la calidad de las soluciones de forma significativa.

Probablemente *El Operador de Cruce Basado en Simulación Binaria* (Simulated Binary Crossover - SBX) [48] es uno de los operadores mas populares en dominios continuos y por lo tanto ha sido utilizado de forma extensiva en muchos MOEAs [35,37]. El operador SBX es clasificado con un operador basado en los padres, lo cual significa las soluciones que corresponden a los hijos (c_1 and c_2) serán creadas alrededor de los valores de los padres (p_1 and p_2). The process of generating the children values is based on a probability distribution. This distribution controls the spread factor $\beta = |c_1 - c_2|/|p_1 - p_2|$ defined as the ratio between the spread of the children values and parent values. In order to define this density function a distribution index η_c (a user-defined control parameter) alters the exploration capability of the operator. Specifically, a small index induces a larger probability of building children values distant to the parent values, whereas high indexes tend to create solutions very similar to the parents as is shown in Figure 3.

The probability distribution to create an offspring value is defined as a function of $\beta \in [0, \infty]$ as follows:

$$P(\beta) = \begin{cases} 0,5(\eta_c + 1)\beta^{\eta_c}, & \text{if } \beta \leq 1 \\ 0,5(\eta_c + 1)\frac{1}{\beta^{\eta_c+2}}, & \text{otherwise} \end{cases} \quad (8)$$

Based in the mean-preserving property of children values and parent values, SBX has the following properties:

- Both offspring values are equi-distant from parent values.
- There exist a non-zero probability to create offspring solutions in the entire feasible space from any two parent values.
- The overall probability of creating a pair of offspring values within the range of parent values is identical to the overall probability of creating two offspring values outside the range of parent values.

Therefore, considering two participating parent values (p_1 and p_2), two offspring values (c_1 and c_2) can be created as linear combination of parent values with a uniform random number $u \in [0, 1]$, as follows:

$$\begin{aligned} c_1 &= 0,5(1 + \beta(u))p_1 + 0,5(1 - \beta(u))p_2 \\ c_2 &= 0,5(1 - \beta(u))p_1 + 0,5(1 + \beta(u))p_2 \end{aligned} \quad (9)$$

The parameter $\beta(u)$ depends on the random number u , as follows:

$$\beta(u) = \begin{cases} (2u)^{\frac{1}{\eta_c+1}}, & \text{if } u \leq 0,5, \\ (\frac{1}{2(1-u)})^{\frac{1}{\eta_c+1}}, & \text{otherwise} \end{cases} \quad (10)$$

The above equation considers an optimization problem with no variable bounds. In most practical problems, each variable is bounded within a lower and upper bound. Thus, the modification of the probability distribution shown in Equation (11) was proposed [49] with the aim of taking into account such bounds. This last variant is extensively used nowadays.

$$\beta(u) = \begin{cases} (2u(1 - \gamma))^{\frac{1}{\eta_c+1}}, & \text{if } u \leq 0,5/(1 - \gamma), \\ (\frac{1}{2(1-u(1-\gamma))})^{\frac{1}{\eta_c+1}}, & \text{otherwise} \end{cases} \quad (11)$$

$$c_1 = 0,5(1 + \beta(u))p_1 + 0,5(1 - \beta(u))p_2 \quad (12)$$

$$c_2 = 0,5(1 + \beta(u))p_1 + 0,5(1 - \beta(u))p_2 \quad (13)$$

In this case, the child c_1 which is nearest to p_1 is calculated according to the Equation (12). Considering that $p_1 < p_2$ and with a lower bound equal to a , $\gamma = 1/(\alpha^{\eta_c+1})$, where $\alpha = 1 + (p_1 - a)/(p_2 - p_1)$. Similarly, the second child c_2 is computed with $\alpha = 1 + (b - p_2)/(p_2 - p_1)$, where b correspond to the upper bound. Then, the second child is computed as is indicated in Equation (13).

Note that as reported in [44] several extensions of the SBX to problems with multiple variables might be provided. Authors considered a simple strategy for choosing the variables to cross [45]. Specifically, each variable is crossed with probability 0.5, following the principles of uniform crossover. Authors recognized the important implications on the linkage among variables of such decisions. In any case, this is the most typical way of applying SBX in problems with multiple variables nowadays.

Algorithm 3 Simulated Binary Crossover (SBX)

```

1: Input: Parents ( $P_1, P_2$ ), Distribution index ( $\eta_c$ ), Crossover probability ( $P_c$ ).
2: Output: Children ( $C_1, C_2$ ).
3: if  $U[0, 1] \leq P_c$  then
4:   for each variable  $d$  do
5:     if  $U[0, 1] \leq \delta_1$  then
6:       Generate  $C_{1,d}$  with Equations (11) and (12).
7:       Generate  $C_{2,d}$  with Equations (11) and (13).
8:       if  $U[0, 1] \leq (1 - \delta_2)$  then
9:         Swap  $C_{1,d}$  with  $C_{2,d}$ .
10:    else
11:       $C_{1,d} = P_{1,d}$ .
12:       $C_{2,d} = P_{2,d}$ .
13: else
14:    $C_1 = P_1$ .
15:    $C_2 = P_2$ .

```




Figure 6 Simulation of the SBX operator sampling 10,000 children values, the parents are located in $P_1 = (-1, 0, -1, 0)$ and $P_2 = (1, 0, 1, 0)$. The left and right are with a distribution index of 2 and 20 respectively.

3.2.2. Implementation and analyses of SBX operator

This section discusses some of the main characteristics of the most currently used implementation of the SBX operator for problems with multiple variables. Essentially, three key components that might affect its performance are discussed. Firstly, as already mentioned it alters each variable with a fixed probability equal to 0,5. If this probability value is increased, the children tend to be more distant to the parents, since in average more variables are modified simultaneously. In separable problems, altering only one variable might be adequate. However, for non-separable problems altering several variables simultaneously seems more promising. The implications of varying this probability is illustrated in Figure 4, where a problem with two variables is taken into account. In the right side a low probability is used and it provokes a bias to explore by keeping some values intact creating a figure similar to a cross in the two-dimensional case. This feature might be suitable for separable problems. Alternatively, the left side shows that when using a high probability this bias disappears, which could be more suitable for non-separable problems. Note that this probability is somewhat related with the distribution index in the sense that both have a direct effect on the similarity between parents and children.

The second key issue is that after generating the two child values with the SBX distribution, such values are interchanged with a fixed probability that is usually set to 0,5, i.e. the value closer to parent p_1 is not always inherited by

c_1 . This is a feature that is not usually discussed but it is important for the obtained performance. In some contexts this probability is known as “Variable uniform crossover probability” [50] or “Discrete Recombination” [51]. Since in multi-objective optimization more diversity is maintained these swaps might produce a high disruptive operator. In fact, in some sense due to this action it is not so clear that SBX can be categorized as a parent-centric operator. These interchanges between the children has the effect of performing multiple “reflections” in the search space. When increasing the dimensions of the decision variables the number of regions covered increases exponentially as is illustrated in Figure 5 where cases with two and three decision variables are taken into account. Note also that this feature has a considerable effect on the distance between parents and offspring.

Finally, the last component is the distribution index, which is probably the most well known feature of the SBX. A low index results in greater exploration levels. In fact, a distribution index equal to one has a similar effect to the Fuzzy Recombination Operator [52]. The effect of applying different indexes is illustrated in Figure 6 where the left side considers a low index value whereas the right side takes into account a higher index value, which creates new candidate solutions that are more similar to the parents.

The SBX implementation is shown in Algorithm 3. This pseudocode is based on the implementation that is integrated in the NSGA-II code published by Deb et al. [35] and which is the most popular variant nowadays. As an input it requires two parents (P_1 and P_2) and it creates two children (C_1 and C_2). The first and second key components commented previously correspond to the lines 5 and 8, respectively. As is usual, for the basic case, SBX is configured with $\delta_1 = \delta_2 = 0,5$ and $\eta_c = 20$. It is important take into account that this implementation does not consider the dimension of the decision variables or the stopping criteria to set any of its internal parameters.

3.3. Propuesta

Based on the previous analyses and with the aim of inducing an appropriate balance between exploration and intensification, the following modifications are proposed. First, the probability to modify a variable (δ_1) is dynamically modified during the execution. The rationality behind this modification is to increase the exploration capability in the initial stages by altering simultaneously several variables and then, as the evolution proceeds reduce the number of variables that are modified. The value of δ_1 is changed in base of a linear decreasing model, where initially it is fixed to 1,0 and then it is decreased so that at the half of total generations is equal to 0,5. This last value is maintained until the end of the execution, i.e. from the half of the execution it behaves as the traditional SBX implementation. Equation (14) is the one used to set the value of δ_1 , where $G_{Elapsed}$ is the current generation and G_{End} is the total number of generations.

Cuadro 5 References points for the HV indicator

Instances	Reference Point
WFG1-WFG9	$[2, 1, \dots, 2m + 0, 1]$
DTLZ 1, 2, 4	$[1, 1, \dots, 1, 1]$
DTLZ 3, 5, 6	$[3, \dots, 3]$
DTLZ7	$[1, 1, \dots, 1, 1, 2m]$
UF 1-10	$[2, \dots, 2]$

Cuadro 6 Statistical Information of Metrics with two objectives

	NSGA-II						MOEA/D						SMS-EMOA					
	1	2	3	4	5	DE	1	2	3	4	5	DE	1	2	3	4	5	DE
Average HV	0.88	0.90	0.90	0.91	0.93	0.94	0.87	0.87	0.87	0.90	0.91	0.91	0.88	0.89	0.87	0.91	0.92	0.93
Average IGD+	0.12	0.09	0.11	0.07	0.06	0.05	0.14	0.12	0.14	0.09	0.08	0.07	0.13	0.11	0.14	0.08	0.07	0.05

Cuadro 7 Statistical Information of Metrics with three objectives

	NSGA-II						MOEA/D						SMS-EMOA					
	1	2	3	4	5	DE	1	2	3	4	5	DE	1	2	3	4	5	DE
Average HV	0.87	0.84	0.87	0.87	0.87	0.85	0.84	0.84	0.84	0.86	0.86	0.85	0.90	0.89	0.88	0.91	0.91	0.91
Average IGD+	0.13	0.16	0.13	0.12	0.12	0.13	0.15	0.14	0.15	0.11	0.11	0.13	0.11	0.11	0.13	0.09	0.09	0.13

In a similar way, the second change is related to the probability of performing reflections $(1 - \delta_2)$. In this case δ_2 is also updated as in Equation (14), meaning that the probability of performing a reflection increases from 0,0 to 0,5 during the execution. This modification is performed with the aim of avoiding the disruptive behavior of interchanging the variables at the first generations because this might result in very drastic modifications. Once that the individuals converge to certain degree it might make more sense to perform such reflections. Thus, this probability is increased to 0,5 which is the value used in the standard implementation of SBX.

$$\delta_1 = \delta_2 = \max \left(0,5, 1,0 - \frac{G_{Elapsed}}{G_{End}} \right) \quad (14)$$

Finally, the distribution index is also changed during the execution. At the first stages a low distribution index is induced with the aim of increasing the exploration capabilities of SBX. Then, it is linearly incremented which has the effect of closing the distribution curve, meaning that more intensification is promoted. The linear increment is governed by Equation (15), meaning that the distribution index is altered from 2 to 22. Note that modifications similar to this last one have been explored previously [53], [40].

$$\eta_c = 2 + 20 \times \left(\frac{G_{Elapsed}}{G_{End}} \right) \quad (15)$$

3.4. Resultados

This section is devoted to analyze the results obtained with the dynamic variants of SBX (DSBX). The novel crossover operator was integrated with NSGA-II, MOEA/D and SMS-EMOA. First, three variants that alter only one of each of the components previously discussed are analyzed. Then, a

Cuadro 8 Summary of Statistical Tests

NSGA-II															
	1			2			3			4			5		
	↑	↓	↔	↑	↓	↔	↑	↓	↔	↑	↓	↔	↑	↓	↔
HV-2obj	16	29	47	6	61	25	28	19	45	31	23	38	54	3	35
HV-3obj	15	19	42	12	50	14	17	15	44	33	10	33	26	9	41
IGD-2obj	14	30	48	4	60	28	25	17	50	33	19	40	52	2	38
IGD-3obj	14	18	44	13	44	19	18	15	43	33	15	28	23	9	44

MOEA/D															
	1			2			3			4			5		
	↑	↓	↔	↑	↓	↔	↑	↓	↔	↑	↓	↔	↑	↓	↔
HV-2obj	15	33	44	10	60	22	25	26	41	39	18	35	57	9	26
HV-3obj	10	22	44	12	39	25	11	19	46	24	10	42	38	5	33
IGD-2obj	16	31	45	9	60	23	23	27	42	37	17	38	57	7	28
IGD-3obj	12	22	42	13	43	20	13	24	39	30	9	37	40	10	26

SMS-EMOA															
	1			2			3			4			5		
	↑	↓	↔	↑	↓	↔	↑	↓	↔	↑	↓	↔	↑	↓	↔
HV-2obj	9	35	48	7	43	42	16	31	45	41	9	42	53	8	31
HV-3obj	7	21	48	9	35	32	13	21	42	27	6	43	31	4	41
IGD-2obj	10	34	48	15	48	29	12	33	47	41	12	39	55	6	31
IGD-3obj	8	20	48	13	30	33	9	19	48	22	5	49	27	5	44

case that alters two of them simultaneously is taken into account. The WFG [54], DTLZ [55] and UF [41] test problems have been used for our purpose. Our experimental validation also includes the variant of Differential Evolution known as DEMO [50] with the aim of comparing our extension of SBX with other well-known operators.

Given that all the methods are stochastic algorithms, each execution was repeated 35 times with different seeds. The common configuration in all of them was the following: the stopping criterion was set to 25,000 generations, the population size was fixed to 100, WFG test problems were configured with two and three objectives, and 24 variables were considered, where 20 of them are distance parameters and 4 of them are position parameters. In the case of the DTLZ test instances, the number of decision variables were set to $n = M + r - 1$, where $r = \{5, 10, 20\}$ for DTLZ1, DTLZ2 to DTLZ6 and DTLZ7 respectively, as is suggested in [55]. In the UF benchmark set the number of decision variables were set to 10. Finally, the polynomial mutation was used with a mutation probability equal to $1/n$ and with a distribution index equal to 50, whereas for the cases that used the SBX, the crossover probability was set to 0.9 and the distribution index was set to 20. The additional parameterization of each algorithm was as follows:

- **DEMO**: CR = 0.3 and F = 0.5.
- **SMS-EMOA**: offset = 100.
- **MOEA/D**: size of neighborhood = 10, max updates by sub-problem (nr) = 2 and $\delta = 0.9$.

In order to compare the fronts obtained by the different methods the normalized hypervolume (HV) and IGD+ was taken into account. The reference points used for the hypervolume indicator are shown in the Table 5 and are similar to the ones used in [56,57].

In order to statistically compare the results (IGD+ and HV values), the following statistical tests were performed. First a Shapiro-Wilk test was performed to check whatever or not the values of the results followed a Gaussian distribution. If, so, the Levene test was used to check for the homogeneity of the variances. If samples had equal variance, an ANOVA test was done; if not, a Welch test was performed. For non-Gaussian distributions, the non-parametric Kruskal-Wallis test was used to test whether samples are drawn from the same distribution. An algorithm X is said to win algorithm Y when the differences between them are statistically significant, and the mean and median obtained by X are higher (in HV) or lower (in IGD+) than the mean and median achieved by Y .

3.5. Analysis of isolated components

In this section we discuss about the independent effect of each component that is dynamically modified. The effect of each component is analyzed through four cases, based in the Algorithm 3. Each case is described as follows:

- **Case 1:** The standard SBX operator where $\delta_1 = \delta_2 = 0,5$ and $\eta_c = 20$.
- **Case 2:** The value δ_1 is updated according to Equation (14), $\delta_2 = 0,5$ and $\eta_c = 20$.
- **Case 3:** The value δ_2 is updated according to Equation (14), $\delta_1 = 0,5$ and $\eta_c = 20$.
- **Case 4:** The distribution index is updated according to Equation (15), $\delta_1 = \delta_2 = 0,5$.

In order to analyze the performance of each Case (Case 5 is discussed later), Tables 6 and 7 shows information about the Normalized Hyper-volume (HV) [53] and about the Inverted Generational Distance Plus (IGD+) [42]. Specifically, the mean of the HV and IGD+ for all considered problems are shown for two and three objectives. It is clear that case 4 outperforms case 1, case 2 and case 3 both with two and three objectives in all the tested algorithms. Therefore, increasing the distribution index during the execution seems to be the most beneficial action. This occurs because the initially open distribution curve leads to a higher degree of exploration, whereas as the evolution proceeds more intensification is promoted. On the other hand, case 2 presented a lower performance than case 1 when taking into account three objectives. Thus, it seems that altering almost all the variables convert the new approach into a too disruptive operator. Perhaps, altering δ_1 in a different way might provide better results, but this is left as a future work.

Previous analyses are only based on the mean obtained for all the problems. However, depending on the problem the performance might vary. This

is analyzed in the following section. Additionally, more detailed results are available².

3.6. Simultaneous modification of several components

Based on the previously discussed results, a variant of the SBX is proposed where the case 3 and case 4 are mixed, i.e. both δ_2 and the distribution index are updated dynamically. Since case 2 did not report significant benefits, the updating mechanism for δ_1 was discarded. Specifically in our case 5, Algorithm 3 is configured as follows. The parameter δ_1 is fixed to 0,5, i.e. in a similar way than the standard SBX. Following the case 3, δ_2 is updated according to Equation (14). Finally, according to case 4 η_c is updated in base of Equation (15).

Attending to the mean HV and IGD+ obtained by the case 5 (see Tables 6 and 7) it is clear that integrating case 3 and case 4 is beneficial. The advantages are clearer in the case of two objectives, whereas in the case of three objectives, case 4 and case 5 are similar in terms of mean performance. Moreover, results attained with case 5 are superior to the ones obtained with DE in three objectives, whereas when using the traditional SBX results deteriorate. Thus, when properly configuring a DSBX results similar or superior to DEMO could be obtained.

Finally, since previous analyses only consider the mean among all the benchmark problems, an additional analyses was developed to better understand the contributions of the different cases. Particularly, pair-wise statistical tests among all the five cases that consider SBX and DSBX were carried out. This was performed independently for NSGA-II, MOEA/D and SMS-EMOA. Results of these statistical tests are shown in Table 8. For each algorithm and case, the column “ \uparrow ” reports the number of comparisons where the statistical tests confirmed the superiority of the corresponding case, whereas the column “ \downarrow ” reports the number of cases where it was inferior and “ \leftrightarrow ” indicates the number of comparisons where differences were not statistically significant. The advantages of case 5 are quite clear. Only in the case of NSGA-II with three objectives, case 4 could outperform the results obtained by case 5. Thus, by properly combining several dynamic modification, results can be improved further. Moreover, results confirm the advantages of our proposals when compared to the standard SBX (case 1). The only case that is not clearly superior to the standard SBX is the case number 2, as it was previously discussed.

Referencias

1. F. Glover, G. Kochenberger, Handbook of metaheuristics (international series in operations research and management science), JOURNAL-OPERATIONAL RESEARCH SOCIETY **56**(5), 614 (2005)

² <https://github.com/joelchaconcastillo/SBX-CEC2018>.

2. U.K. Chakraborty, *Advances in differential evolution*, vol. 143 (Springer, 2008)
3. F. Herrera, M. Lozano, Adaptation of genetic algorithm parameters based on fuzzy logic controllers, *Genetic Algorithms and Soft Computing* **8**, 95 (1996)
4. M. Črepinšek, S.H. Liu, M. Mernik, Exploration and exploitation in evolutionary algorithms: A survey, *ACM Computing Surveys* **45**(3), 35:1 (2013)
5. D. Dasgupta, Z. Michalewicz, *Evolutionary algorithms in engineering applications* (Springer Science & Business Media, 2013)
6. H.M. Pandey, A. Chaudhary, D. Mehrotra, A comparative review of approaches to prevent premature convergence in ga, *Applied Soft Computing* **24**, 1047 (2014)
7. T. Blickle, L. Thiele, A comparison of selection schemes used in evolutionary algorithms, *Evolutionary Computation* **4**(4), 361 (1996)
8. K.A. De Jong, *Evolutionary computation: a unified approach* (MIT press, 2006)
9. S.W. Mahfoud, Crowding and preselection revisited, *Urbana* **51**, 61801 (1992)
10. M. Lozano, F. Herrera, J.R. Cano, Replacement strategies to preserve useful diversity in steady-state genetic algorithms, *Information Sciences* **178**(23), 4421 (2008)
11. A.E. Eiben, C.A. Schippers, On evolutionary exploration and exploitation, *Fundamenta Informaticae* **35**(1-4), 35 (1998)
12. R. Storn, K. Price, Differential evolution—a simple and efficient heuristic for global optimization over continuous spaces, *Journal of global optimization* **11**(4), 341 (1997)
13. S. Das, P.N. Suganthan, Differential evolution: A survey of the state-of-the-art, *IEEE transactions on evolutionary computation* **15**(1), 4 (2011)
14. J.A. Nelder, R. Mead, A simplex method for function minimization, *The computer journal* **7**(4), 308 (1965)
15. W. Price, Global optimization by controlled random search, *Journal of Optimization Theory and Applications* **40**(3), 333 (1983)
16. J. Zhang, A.C. Sanderson, Jade: adaptive differential evolution with optional external archive, *IEEE Transactions on evolutionary computation* **13**(5), 945 (2009)
17. Á.A. Sá, A.O. Andrade, A.B. Soares, S.J. Nasuto, in *AISB 2008 Convention Communication, Interaction and Social Intelligence*, vol. 1 (2008), vol. 1, p. 57
18. J. Lampinen, I. Zelinka, et al., in *Proceedings of MENDEL* (2000), pp. 76–83
19. D. Zaharie, in *Proc. of MENDEL*, vol. 9 (2003), vol. 9, pp. 41–46
20. M. Yang, C. Li, Z. Cai, J. Guan, Differential evolution with auto-enhanced population diversity, *IEEE transactions on cybernetics* **45**(2), 302 (2015)
21. J. Montgomery, in *Evolutionary Computation, 2009. CEC'09. IEEE Congress on* (IEEE, 2009), pp. 2833–2840
22. J. Montgomery, S. Chen, in *Evolutionary Computation (CEC), 2012 IEEE Congress on* (IEEE, 2012), pp. 1–8
23. A. Bolufé-Röhler, S. Estévez-Velarde, A. Piad-Morffis, S. Chen, J. Montgomery, in *Evolutionary Computation (CEC), 2013 IEEE Congress on* (IEEE, 2013), pp. 40–47
24. C. Segura, C.A.C. Coello, E. Segredo, A.H. Aguirre, A novel diversity-based replacement strategy for evolutionary algorithms, *IEEE transactions on cybernetics* **46**(12), 3233 (2016)
25. J. Montgomery, S. Chen, in *Evolutionary Computation (CEC), 2010 IEEE Congress on* (IEEE, 2010), pp. 1–8
26. N.H. Awad, M.Z. Ali, P.N. Suganthan, R.G. Reynolds, in *Evolutionary Computation (CEC), 2016 IEEE Congress on* (IEEE, 2016), pp. 2958–2965
27. J. Brest, M.S. Maučec, B. Bošković, in *Evolutionary Computation (CEC), 2016 IEEE Congress on* (IEEE, 2016), pp. 1188–1195
28. S. Elsayed, N. Hamza, R. Sarker, in *Evolutionary Computation (CEC), 2016 IEEE Congress on* (IEEE, 2016), pp. 2966–2973
29. A. Kumar, R.K. Misra, D. Singh, in *Evolutionary Computation (CEC), 2017 IEEE Congress on* (IEEE, 2017), pp. 1835–1842
30. J. Brest, M.S. Maučec, B. Bošković, in *Evolutionary Computation (CEC), 2017 IEEE Congress on* (IEEE, 2017), pp. 1311–1318
31. D. Molina, F. Moreno-García, F. Herrera, in *Evolutionary Computation (CEC), 2017 IEEE Congress on* (IEEE, 2017), pp. 805–812
32. J.J. Durillo, A.J. Nebro, C.A.C. Coello, J. Garcia-Nieto, F. Luna, E. Alba, A Study of Multiobjective Metaheuristics When Solving Parameter Scalable Problems, *IEEE Transactions on Evolutionary Computation* **14**(4), 618 (2010)

33. A.G. Slim Bechikh, Rituparna Datta, *Recent Advances in Evolutionary Multi-objective Optimization* (Springer)
34. M. Pilát, Evolutionary multiobjective optimization: A short survey of the state-of-the-art, *Proceedings of the Contributed Papers Part I-Mathematics and Computer Sciences*, WDS, Prague, Czech pp. 1–4 (2010)
35. K. Deb, A. Pratap, S. Agarwal, T. Meyarivan, A fast and elitist multiobjective genetic algorithm: NSGA-II, *IEEE Transactions on Evolutionary Computation* **6**(2), 182 (2002)
36. Q. Zhang, H. Li, MOEA/D: A Multiobjective Evolutionary Algorithm Based on Decomposition, *IEEE Transactions on Evolutionary Computation* **11**(6), 712 (2007)
37. N. Beume, B. Naujoks, M. Emmerich, SMS-EMOA: Multiobjective selection based on dominated hypervolume, *European Journal of Operational Research* **181**(3), 1653 (2007)
38. C. Horoba, F. Neumann, in *Proceedings of the 10th annual conference on Genetic and evolutionary computation* (ACM, 2008), pp. 641–648
39. K. Price, R.M. Storn, J.A. Lampinen, *Differential evolution: a practical approach to global optimization* (Springer Science & Business Media, 2006)
40. M. Hamdan, in *International Conference on Electronics Computer Technology*, Kanayakumari, India (2012)
41. Q. Zhang, W. Liu, H. Li, in *Evolutionary Computation, 2009. CEC'09. IEEE Congress on* (IEEE, 2009), pp. 203–208
42. H. Ishibuchi, H. Masuda, Y. Tanigaki, Y. Nojima, in *International Conference on Evolutionary Multi-Criterion Optimization* (Springer, 2015), pp. 110–125
43. L.J. Eshelman, Real coded genetic algorithms and interval-schemata, *Foundations of genetic algorithms* **2**, 187 (1993)
44. R.B. Agrawal, K. Deb, K. Deb, R.B. Agrawal, Simulated binary crossover for continuous search space. Tech. rep. (1994)
45. I. Ono, H. Kita, S. Kobayashi, (Springer-Verlag New York, Inc., New York, NY, USA, 2003), chap. A Real-coded Genetic Algorithm Using the Unimodal Normal Distribution Crossover, pp. 213–237. URL <http://dl.acm.org/citation.cfm?id=903758.903767>
46. R. Storn, K. Price, Differential evolution – a simple and efficient heuristic for global optimization over continuous spaces, *J. of Global Optimization* **11**(4), 341 (1997). DOI 10.1023/A:1008202821328. URL <http://dx.doi.org/10.1023/A:1008202821328>
47. H. Jain, K. Deb, Parent to mean-centric self-adaptation in sbx operator for real-parameter optimization, *Swarm, Evolutionary, and Memetic Computing* pp. 299–306 (2011)
48. K. Deb, R.B. Agrawal, Simulated binary crossover for continuous search space, *Complex Systems* **9**(3), 1 (1994)
49. K. Deb, H.G. Beyer, *Self-adaptive genetic algorithms with simulated binary crossover* (Secretary of the SFB 531, 1999)
50. T. Tušar, B. Filipič, in *International Conference on Evolutionary Multi-Criterion Optimization* (Springer, 2007), pp. 257–271
51. H. Mühlenbein, D. Schlierkamp-Voosen, Predictive models for the breeder genetic algorithm i. continuous parameter optimization, *Evolutionary computation* **1**(1), 25 (1993)
52. H.M. Voigt, H. Mühlenbein, D. Cvetkovic, in *Proc. Sixth Int. Conf. on Genetic Algorithms* (Citeseer, 1995)
53. E. Zitzler, L. Thiele, Multiobjective evolutionary algorithms: a comparative case study and the strength pareto approach, *IEEE transactions on Evolutionary Computation* **3**(4), 257 (1999)
54. S. Huband, L. Barone, L. While, P. Hingston, *A Scalable Multi-objective Test Problem Toolkit* (Springer Berlin Heidelberg, Berlin, Heidelberg, 2005), pp. 280–295
55. K. Deb, L. Thiele, M. Laumanns, E. Zitzler, *Scalable test problems for evolutionary multiobjective optimization* (Springer, 2005)
56. J.A.M. Berenguer, C.A.C. Coello, in *International Conference on Evolutionary Multi-Criterion Optimization* (Springer, 2015), pp. 3–17
57. Q. Zhu, Q. Lin, Z. Du, Z. Liang, W. Wang, Z. Zhu, J. Chen, P. Huang, Z. Ming, A novel adaptive hybrid crossover operator for multiobjective evolutionary algorithm, *Information Sciences* **345**, 177 (2016)